



Семинарска задача по предметот

Вовед во наука на податоци

ТЕМА: Алгоритам за динамичко поставување на цени на производи од различни категории врз база на побарувачката и конкуренцијата

Линк до GitHub репозиториум

<https://github.com/andrejpanev8/vnp-project>

Професор / ментор:

Асис. Милена Трајановска

Скопје, 2025

Изработил:

Андреј Панев, 211066

Содржина

1. Вовед.....	2
1.1 Опис на темата.....	2
1.2 Цел на темата.....	2
2. Датасет.....	3
2.1 Атрибути.....	3
3. Анализа на податоци.....	4
3.1 Конструкција на датасет.....	4
3.2 Корелација.....	4
3.3 Распределба.....	6
4. Средување атрибути.....	8
5. Нормализација.....	8
6. Модел.....	9
6.1 Земање примероци.....	10
6.2 Тренирање на модел.....	10
6.3 Евалуација на модел.....	11
7. Резултати.....	13
7.1 Функција за динамичко одредување на цените.....	13
7.2 Евалуација на резултати.....	14
8. Заклучок.....	15
9. Референци.....	15

1. Вовед

Во современото динамично пазарно опкружување, цените на производите се подложни на постојани промени поради различни фактори како побарувачка, конкуренција, состојба на залихи и сл. Затоа се повеќе компании се стремат кон автоматизирани и интелигентни решенија за поставување на цените на своите производи со цел зголемување на продажбата и профитот.

Динамичкото поставување на цени претставува процес на предвидување и адаптирање на цените на производите во реално време или со минимално задоцнување, врз основа на историски податоци и тековни пазарни индикатори. Овој пристап овозможува бизнисите да реагираат на пазарните промени и да го максимизираат приходот со понуда на соодветна цена во вистински момент.

1.1 Опис на темата

Во рамките на овој проект, користен е **Retail Store Inventory Forecasting** dataset, кој содржи информации поврзани со продажбата, залихите, нарачките, попустите и конкурентските цени во еден малопродажан ланец. Со примена на напреден машински алгоритам за регресија (како што е XGBoost) изграден е модел за предвидување на цените на производите, како и за препорака на оптимални динамички прилагодени цени базирани на историските трендови и пазарните услови.

1.2 Цел на темата

Целта на овој проект е да се развие интелигентен систем за динамичка предикција и препорака на цени на производи во малопродажна средина, користејќи реални податоци. Конкретно, проектот има за цел:

- Да се анализираат и разберат факторите што најмногу влијаат врз цената на производите.
- Да се изгради модел за регресија кој ќе може да ја предвиди цената на производ базирано на историски и моментални податоци.
- Да се развие динамичен механизам за препорака на оптимална цена.
- Да се спореди точноста на предвидените цени со реалните вредности и да се анализира перформансот на моделот преку метрики како MAE, RMSE и MAPE.
- Да се визуелизираат резултатите и да се обезбеди поддршка за донесување одлуки врз основа на податоци.

Преку реализација на овие цели, проектот покажува како предиктивното моделирање и автоматизирани ценообразовни системи можат да се применат во реални бизнис-сценарија за да се зголемат профитите и оперативната ефикасност.

2. Датасет

За реализација на овој проект се користи синтетичен но прилично реалистично моделиран датасет од Kaggle, насловен како **Retail Store Inventory Forecasting Dataset**, кој содржи податоци од малопродажна продавница поврзани со продажба, залиха, цени и други релевантни информации за предвидување на динамична цена.

2.1 Атрибути

Датасетот се состои од неколку илјади редови и ги опфаќа следните атрибути:

- **Date** – Датум на набљудување.
- **Store ID** – Идентификатор на продавницата
- **Product ID** – Идентификатор на производот
- **Category** – Категорија на производот
- **Region** – Регион во кој се наоѓа продавницата (Исток, Запад, Север, Југ).
- **Inventory Level** – Ниво на залиха на производот.
- **Units Sold** – Број на продадени единици за дадениот датум.
- **Units Ordered** – Број на нарачани единици (побарувачка).
- **Demand Forecast** – Предвидување за побарувачката.
- **Price** – Реална цена на производот (таргет променлива).
- **Discount** – Попуст изразен како дел од цената.
- **Weather Condition** – Какво било времето во моментот на разгледување на цените.
- **Holiday/Promotion** – Дали денот е празник или има промоција (бинарна променлива).
- **Competitor Pricing** – Цена на конкурентен производ.
- **Seasonality** – Сезона (Пролет, Лето, Есен, Зима).

3. Анализа на податоци

3.1 Конструкција на датасет


При анализа на датасетот можеме да воочеме дека датасетот се состои од податоци од податочните типови object (текст), int (цели броеви), float (децимални броеви).

- **Текстуални** - Date, Store ID, Product ID, Category, Region, Weather Condition, Seasonality
- **Цели броеви** - Inventory level, Units Sold, Units Ordered, Discount, Holiday/Promotion
- **Децимални броеви** - Demand forecast, Price, Competitor Pricing

Во датасетот исто така нема празни полиња, и нема дупликат записи.

3.2 Корелација

Ако ги издвоиме цифрените податоци од датасетот, можеме да ја анализираме нивната корелација, која укажува колку ови атрибути имаат меѓусебно влијание. Со вака издвоените атрибути ја добиваме следната матрица на Слика 1.




Слика 1

Од оваа матрица на корелација може да заклучиме дека **цената** има многу силна позитивна врска со **конкурентската цена**. Ова сугерира директна врска и веројатна стратегија за усогласување на цените со конкуренцијата. Малите корелации со другите променливи покажуваат дека одлуките за цените на продавницата се прилично независни од овие фактори, барем во линеарна смисла.


Но сепак корелацијата не подразбира каузалност. Иако цените на конкуренцијата силно корелираат со цената на продавницата, не можеме дефинитивно да кажеме дека цените на конкуренцијата предизвикуваат промена на цената на продавницата има и други основни фактори кои влијаат на двете.

Сепак иако со мала корелација, и останатите атрибути може да се земат во предвид, на следната Слика 2 е визуелизирана нивната меѓусебна споредба со и без корелацијата на цената со конкурентите.



Слика 2


Треба да се провери дали цената има некој тренд на покачување или намалување со тек на време, па според Слика 3, може да забележиме дека цената прилично се движи околу средната вредност односно во овој случај инфлацијата е изоставена од цената (веројатно поради тоа што работиме со синтетички датасет).



Слика 3

3.3 Распределба


Прво ќе ја погледнеме распределбата на цената Слика 4



Слика 4


Според овој график може да се забележи дека цената има прилично рамномерна распределба, ова значи дека не постои тесен опсег околу кој се базираат цените односно цени кои се значително почести од другите. Иако има мали варијации, целокупната слика укажува на прилично рамномерен распоред на цените. Ова сугерира дека инвентарот се состои од широк спектар на малопродажни производи од во секој опсег на цени.

Сега ова може да го провериме со споредба на просечната цена со просечната количина на продадени производи според категорија на Слика 5. Според графикот може да се забележи дека во сите категории просечната цена е приближно иста, како и просечната количина на продадени производи по категорија е исто така иста. Од ова може да заклучиме дека Купувачите, во просек, плаќаат слична цена без оглед на тоа дали купуваат облека, електроника, мебел, намирници или играчки. Просекот на продадени производи е исто така доста сличен низ категориите, што покажува дека секоја категорија придонесува релативно рамномерно кон вкупниот обем на продажба.



Слика 5

Дополнително информативно може да ја погледнеме и дистрибуцијата на продадени единици по производ. Повеќето производи имаат релативно ниска продажба, додека само мал број од нив се продаваат во големи количини. Оваа информација е корисна за донесување одлуки во врска со управувањето со залихите.



Слика 6

4. Средување атрибути

За да ги доведеме атрибутите до степен разбирлив за моделот, треба да ги превземеме следните чекори.

1. Колоната Date ја конвертираме во Pandas datetime објект - Потречно за сортирање по датум.
2. Сортирање на датасетот по датум.
3. Извлекување на година, месец, ден, датум, ден од недела како посебни атрибути.

Моделите за машинско учење работат со нумерички податоци. Извлекувањето на овие компоненти го претвора datetime објектот во формат кој може да го користи моделот.

4. Конверзија на категоријалните атрибути како нумерички во one-hot encoding репрезентација

Ако категоријалните променливи би биле оставени како текстуални или дури и претворени во едноставни нумерички кодови (на пример, 1 за категорија А, 2 за категорија Б), моделот може погрешно да научи нумерички односи помеѓу категориите кои не постојат (на пример, дека категорија Б е "поголема" од категорија А). One-hot encoding креира посебна бинарна колона за секоја категорија, елиминирајќи го овој проблем.

5. Нормализација

Дел од атрибутите треба да бидат нормализирани за да може моделот да ги користи. За да се постигне ова ќе бидат преземени неколку чекори.

- Енкодорање на Store ID и Product ID со LabelEncoder, овие атрибути ни се потребни бидејќи содржат контекстуални информации кои можат да влијаат на цената, односно различни продавници може да имат различна стратегија за поставување на цената.
- Додавање нови атрибути за цената Price_lag1 - цената на производот во претходниот временски чекор и Price_roll3 - подвижен просек на цената во последните 3 временски чекори

Цените честопати се автокорелирани, што значи дека тековната цена е поврзана со претходните цени. Овие заостанати и подвижни просечни карактеристики му овозможуваат на моделот да ги фати овие краткорочни трендови и континуитет во

цените. Подвижниот просек може да помогне во измазнување на краткорочните флукутации на цените и да го истакне израмнетиот тренд.

- Додавање нов атрибут за подвижен просек на продадени единици по продавница `Store_UnitsSold_roll7`, за секоја продавница се пресметува подвижниот просек на продадени единици за претходните 7 временски чекори. Неодамнешниот просек на продадени единици може да послужи како индиректен показател за локалната побарувачка во секоја продавница, што може да влијае на цените. Како и атрибут за подвижен просек на цени по производ `Product_Price_roll3`, за секој производ се пресметува подвижниот просек на цената за претходните 3 временски чекори (слично како `Price_roll3`, но специфично за секој производ). Цените на одделните производи може да имаат свои уникатни трендови поради фактори како што се промени во понудата и побарувачката, акции на конкуренцијата или стратегии за цени специфични за производот. Оваа карактеристика му овозможува на моделот да ги земе во предвид овие специфични динамики на цените.

После овие трансформации, проверуваме дали имаме редови со вредности кои недостигаат. Во овој случај имаме само 3 празни вредности за `Price_lag1` една и `Price_roll3` две, со што овие редови можеме да ги изоставиме од сетот со бришење бидејќи се многу малку и нивното бришење нема да има ефект на учењето на моделот.

6. Модел

За проблемот со динамичко поставување на цени ќе го искористиме **XGBoost** моделот, причини за овој избор се:

- Добро справување со не линеарни односи, пример цената е зависна од сложени не линеарни фактори како промоции, празници, сезони и слично.
- Справување со сложени интеракции меѓу атрибутите, пример попустот на некој производ може да има различен ефект во зависност од категоријата или периодот од годината.
- Заштита од **Overfitting**, XGBoost има механизми за регуларизација кои помагаат да се спречи **Overfitting** на податоците за тренирање на моделот. Ова е особено важно за временска серија каде имаме доста шум, пример цената на производот ([3.2 Корелација](#) - Слика 3).

6.1 Земање примероци

Датасетот го делиме на две множества каде во едното се атрибутите на кои ќе се тренира моделот (множество X), од ова множество ќе ги исклучиме датумот и цената, а другото ќе биде соодветната цена (множество Y).

Соодветно овие множества ги делиме на X_{train} , X_{test} , Y_{train} , Y_{test} , каде поделбата означува парови X_{train} - Y_{train} (множества за тренирање на моделот) и парови X_{test} - Y_{test} (множества за тестирање на моделот). За множеството за тренирање земаме 80% од почетното множество, а последните 20% ги оставаме за тестирање.

При што добиваме големина на множествата 58478 примероци за тренирање и 14620 примероци за тестирање.

6.2 Тренирање на модел

Моделот го поставуваме како **XGBRegressor** со следните параметри:

- `n_estimators = 100`

Овој параметар го контролира бројот на дрвја за засилување. 100 е добра почетна вредност. Повеќе дрвја може да доведат до подобра точност, но исто така и до поголем ризик за *overfitting* и подолго време на тренирање.

- `learning_rate=0.1`

Оваа вредност ја контролира стапката на учење, односно колку силно се прилагодуваат тежините на моделот во секоја итерација. Помала стапка на учење може да доведе до попрецизен модел, но бара повеќе дрвја. 0.1 е често користена вредност и сосема доволна во овој случај.

- `max_depth=5`

Овој параметар ја ограничува максималната длабочина на секое дрво, што помага во спречување на *overfitting*. 5 е добра вредност што му овозможува на моделот да научи сложени односи помеѓу атрибутите без да стане премногу специфичен за тренинг датасетот.

- `random_state=42`

Поставувањето на `random_state` обезбедува репродуктивност на резултатите. Секогаш кога ќе се изврши кодот, моделот ќе биде иницијализиран на ист начин.

Оваа поставеност ги комбинира соодветната подготовка на податоците за временски серии со моќен и модел како XGBoost, овозможувајќи му да научи од минатите податоци и да прави разумни предвидувања за идните цени. Сепак, перформансите на моделот ќе зависат и од квалитетот и количината на податоците.

6.3 Евалуација на модел

За точно да го евалуираме моделот треба прво да ги разгледаме минималната, просечната и максималната вредност во цените. Односно следните:

- Min Price: 10.0
- Average Price: 55.135
- Max Price: 100.0

Сега резултатите од моделот ќе ги евалуираме според MAE, RMSE, MAPE.

- MAE (Mean Absolute Error):

Резултат - 2.38

Просечната апсолутна грешка изнесува 2.38. Ова значи дека во просек, предвидените цени отстапуваат од вистинските цени за 2.38 единици. Во однос на опсегот на цени (10-100) и просечната цена (55.135), грешка од 2.38 може да се смета за релативно мала.

- RMSE (Root Mean Squared Error):

Резултат - 2.78


Квадратниот корен од средната квадратна грешка е 2.78. RMSE дава поголема тежина на поголемите грешки во споредба со MAE. Разликата помеѓу RMSE (2.78) и MAE (2.38) сугерира дека моделот има стабилни предвидувања со грешки во неколку поголеми екстреми (outliers). Но сепак слично како MAE, RMSE од 2.78 изгледа прилично добро во однос на скалата на цените.

- MAPE (Mean Absolute Percentage Error):

Резултат - 5.93%


Просечната апсолутна процентна грешка е 5.93%. Ова значи дека во просек, предвидените цени отстапуваат од вистинските цени за 5.93% од вистинската цена. MAPE од под 6% обично се смета за добар резултат во многу апликации за предвидување. Тоа укажува дека моделот има релативно висока точност во предвидувањето на цените во однос на нивната вистинска вредност.

Сега ќе извадиме 100 примери од реални цени и предвидени цени, според кои ќе можеме визуелно да го претставиме перформансот на моделот. Пример на слика 7 од случајно избраните примероци, моделот успешно ја предвидува цената со минимални отстапки.



Слика 7

Споредбата може да ја направиме и во временски интервал, каде може да се примети дека како со тек на време се менуваат цените, моделот успешно успева и се адаптира на промените, што сугерира дека моделот ги има научено комплексните соодноси помеѓу атрибутите кои предизвикуваат промена на трендот на цената. Ова може да се види на слика 8



Слика 8

7. Резултати

За крај на овој модел може да му се додаде и дополнителен алгоритам според кој ќе се вршат дополнителни корекции во случај предвидената цена на моделот не соодветствува според нашите политики за поставување на цените.

7.1 Функција за динамичко одредување на цените


Алгоритмот го користи предвидениот модел за цена, но врши корекции врз основа на неколку реални услови. Доколку бројот на продадени единици ја надминува прогнозата за побарувачка и конкурентската цена е пониска од предвидената, тогаш се предлага цена пониска за 0.50 од конкурентската со цел да се задржи конкурентноста. Во случај кога залихата е ниска (помала од 50 единици), цената се зголемува за 5% со цел да се искористи моментот на поголема побарувачка. Во сите други случаи се предлага основната, предвидена цена. Овој пристап овозможува флексибилно приспособување кон пазарните услови и потенцијално зголемување на профитот преку динамично прилагодување на цената. На табелата на слика 9 може да видиме 15 примероци од вистинската цена, предвидената, динамички препорачаната и цената на конкуренцијата.

	Actual Price	Predicted Price	Dynamic Recommendation	Competitor Pricing
Date				
2023-10-02	24.94	24.533930	23.030000	23.53
2023-08-18	80.78	81.486626	81.486626	81.58
2023-08-29	87.06	84.871826	84.200000	84.70
2023-12-07	32.78	28.388464	28.388464	28.48
2023-09-10	93.67	96.449928	96.449928	98.19
2023-11-05	36.74	38.701744	37.380000	37.88
2023-10-13	76.50	71.487640	71.487640	71.56
2023-09-23	19.95	20.167738	20.167738	19.73
2023-10-16	90.86	93.532158	93.532158	93.67
2023-08-27	55.80	60.127110	60.127110	60.19
2023-12-25	95.00	91.251328	91.251328	90.97
2023-09-14	76.88	78.505257	78.505257	78.60
2023-12-01	68.27	67.203209	67.203209	67.69
2023-11-16	94.58	90.098167	90.098167	90.54
2023-09-09	53.49	53.878422	53.878422	54.32

Слика 9

7.2 Евалуација на резултати

За крај ќе земеме 50 случајни примероци со динамички прилагодени цени, и ќе ги споредиме со вистинската цена, предвидената и цената на конкуренцијата. Резултатите се прикажани на слика 10.



Слика 10

8. Заклучок

Преку овој проект за динамичко поставување на цени во малопродажба, беше прикажано како машинското учење може ефикасно да се искористи за донасање на информирани одлуки во реално време. Со користење на синтетички датасет и имплементација на модел за регресија, успешно ја предвидовме цената на производи базирано на различни фактори како залиха, побарувачка, попусти и конкурентски цени. Дополнително, беше развиен алгоритам за динамичка препорака на цена кој паметно ги прилагодува цените во согласност со пазарната состојба. Ова решение демонстрира потенцијал за практична примена во модерното управување со цени, зголемување на приходите и подобро пазарно прилагодување. Проектот покажува дека комбинирањето на предиктивна анализа и бизнис логика може да доведе до значајни подобрувања во процесот на одлучување.

9. Референци

Датасет:

<https://www.kaggle.com/datasets/anirudhchauhan/retail-store-inventory-forecasting-dataset>

Анализа:

<https://www.kaggle.com/code/beshoyemad24/retail-store-inventory-forecastin-eda-prediction>

Запознавање со доменот на проблемот: <https://sbgfunding.com/factors-of-pricing/>

Разгледување можни опции за избор на модел за предвидување на цените:

<https://www.n-ix.com/price-optimization-machine-learning/>